

# Método Bootstrap

Rodrigo Barrera

## ① Introducción

- Antecedentes históricos
- Generalidades

## ② Bootstrap No Paramétrico (Efron)

- Método
- Justificación Matemática para Bootstrap Clásico

## ③ Bootstrap Paramétrico

- Método

## ④ Referencias

## ① Introducción

Antecedentes históricos

Generalidades

## ② Bootstrap No Paramétrico (Efron)

Método

Justificación Matemática para Bootstrap Clásico

## ③ Bootstrap Paramétrico

Método

## ④ Referencias

**Descripción:** técnica en la clase de métodos que remuestrean a partir del set de datos original. Algunos procedimientos similares:

- **Jackknife:** Quenouille (1949).
- **Métodos de permutaciones:** Fisher y Pitman (1930).

Nombre: “to pull oneself up by one’s (own) bootstraps”. Conecta con la idea de realizar “lo imposible” con información limitada (tamaño de la muestra, desconocimiento de la distribución).

## Línea de tiempo:

- **Efron (1979):** unifica y conecta ideas sobre Bootstrap no paramétrico, para observaciones independientes e idénticamente distribuidas (remuestreo con reposición).
- **1980's:** Avances teóricos y estudios de simulaciones que compararon el Bootstrap y sus variantes con estimadores de otros procedimientos.
- **1990's:** cambio de foco a un desarrollo más práctico: aplicación a diversos contextos y cómo se comportan los resultados de distintas variantes.

- **Computacionalmente intensivos:** en problemas prácticos, cuando la estimación es compleja, se requieren múltiples muestras bootstrap (Chernick (2008) sugiere extraer como mínimo 1000 muestras bootstrap).
- **Versión clásica o No Paramétrica de Efron:** no asume una distribución específica, solamente que la muestra es iid.
- **Versión Paramétrica:** asume un modelo paramétrico (Normal, Exponencial, etc.) y se utiliza para conocer información sobre algún parámetro.

De acuerdo con Chernick (2008):

- **Muestra muy pequeña:** con pocos valores desde donde remuestrear, Bootstrap subrepresentará la verdadera variabilidad del estadístico bajo estudio.
- **Varianza no finita:** Athreya (1987) estudia casos específicos en donde Bootstrap podría tener buen desempeño para la media.
- **Estimación de valores extremos:** método falla cuando el estadístico a describir es el mínimo o máximo.
- **Encuestas:** si la relación entre tamaño muestral y tamaño poblacional no es pequeña, la variabilidad estimada por Bootstrap se ve reducida.

## ① Introducción

Antecedentes históricos

Generalidades

## ② Bootstrap No Paramétrico (Efron)

Método

Justificación Matemática para Bootstrap Clásico

## ③ Bootstrap Paramétrico

Método

## ④ Referencias



# Bootstrap No Paramétrico

Suponer una muestra iid:  $X_1, X_2, \dots, X_n \sim F$

Se busca estudiar (ejemplo) la Mediana de la distribución. Calculamos:  
 $M_n = \text{median}(X_1, \dots, X_n)$

$B$  muestras bootstrap (muestreo con reposición):

$$\begin{array}{ccc} X_1^{*(1)}, & \dots, & X_n^{*(1)} \\ \vdots & \ddots & \vdots \\ X_1^{*(B)}, & \dots, & X_n^{*(B)} \end{array}$$

$B$  medianas:  $M_n^{*(1)}, \dots, M_n^{*(B)}$

- ① Estimador de la varianza:

$$\widehat{Var}_B(M_n) = \frac{1}{B-1} \sum_{l=1}^B (M_n^{*(l)} - \bar{M}_B^*)^2$$

- ② Estimador del sesgo:  $\widehat{Bias}_B(M_n) = \frac{1}{B} \sum_{l=1}^B (M_n^{*(l)}) - M_n$

- ③ Estimador de MSE:  $\widehat{MSE}(M_n) = \frac{1}{B} \sum_{l=1}^B (M_n^{*(l)} - M_n)^2$

- ④ IC  $(1 - \alpha)$  :  $M_n \pm z_{1-\alpha/2} \sqrt{\widehat{Var}_B(M_n)}$  (Normalidad asintótica)

- ⑤ IC  $(1 - \alpha)$  :  $[M_{n,\alpha/2}^*, M_{n,1-\alpha/2}^*]$  (Percentiles)

Siguiendo la notación de Dikta y Scheer (2021):

- Muestra iid:  $X_1, \dots, X_n \sim F$
- Estadístico de interés:  $T_n(F) = T_n(X_1, \dots, X_n; F)$
- Se busca aproximar su distribución, por ejemplo para estudiar IC.
- Bootstrap clásico:  $T_n(\hat{F}) = T_n(F_n) = T_n(X_1^*, \dots, X_n^*; F_n)$ , en donde  $X_1^*, \dots, X_n^* \sim F_n$  es muestra iid (muestra bootstrap).
- $E(X) = \mu$  y  $Var(X) = \sigma^2$

## Ley Débil de los Grandes Números (Bootstrap)

Asumiendo que  $\int |h(x)|F(dx) < \infty$ , entonces con probabilidad 1, para cada  $\epsilon > 0$ :

$$P_n^*\left(\left|\frac{1}{n} \sum_{i=1}^n h(X_i^*) - \int h(x)F(dx)\right| > \epsilon\right) \rightarrow 0$$

cuando  $n \rightarrow \infty$

En este punto se asume:

- $E(X) = \mu$
- $V(X) = \sigma^2$

## Teorema de Límite Central (Bootstrap)

Considerando  $E(X^2) < \infty$  y  $E(X) = \mu$ , entonces con probabilidad 1:

$$\sup_{x \in \mathbb{R}} |P(\frac{1}{n^{-1/2}} \cdot (\bar{X}_n - \mu) \leq x) - P_n^*(\frac{1}{n^{-1/2}} \cdot (\bar{X}_n^* - \bar{X}_n) \leq x)| \rightarrow 0$$

cuando  $n \rightarrow \infty$

## Corolario

Bajo los supuestos del Teorema anterior, con probabilidad 1:

$$\sup_{x \in \mathbb{R}} |P(\frac{1}{n^{-1/2}} \cdot (\bar{X}_n - \mu)/s_n \leq x) - P_n^*(\frac{1}{n^{-1/2}} \cdot (\bar{X}_n^* - \bar{X}_n)/s_n^* \leq x)| \rightarrow 0$$

cuando  $n \rightarrow \infty$

## Teorema de Berry-Esseen

Sea  $X_1, \dots, X_n$  una muestra iid, con media  $\mu$  y varianza  $\sigma^2$ . Sea  $\mu_3 = E[|X_i - \mu|^3] < \infty$ . Sea  $\bar{X}_n = n^{-1} \sum_{i=1}^n X_i$  la media muestral y sea  $\Phi$  la cdf asociada a una v.a. que distribuye  $N(0, 1)$ . Sea  $Z_n = \frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma}$ . Entonces:

$$\sup_x |P(Z_n \leq x) - \Phi(x)| \leq \frac{C \cdot \mu_3}{\sigma^3 \cdot \sqrt{n}}, \quad C \geq \frac{\sqrt{10} + 3}{6\sqrt{2\pi}}$$

## ① Introducción

Antecedentes históricos

Generalidades

## ② Bootstrap No Paramétrico (Efron)

Método

Justificación Matemática para Bootstrap Clásico

## ③ Bootstrap Paramétrico

Método

## ④ Referencias

# Bootstrap Paramétrico

Se supone en este caso que se quiere recabar información sobre el parámetro de una distribución.

Ejemplo: muestra iid  $X_1, X_2, \dots, X_n \sim N(0, \sigma^2)$ ,  $\sigma^2$  es desconocida.

Estimador insesgado para la varianza poblacional:

$$S_n^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2$$

$$\begin{array}{l} B \text{ muestras bootstrap: } \begin{array}{ccc} X_1^{*(1)}, & \dots, & X_n^{*(1)} \sim N(0, S_n^2) \\ \vdots & \ddots & \vdots \\ X_1^{*(B)}, & \dots, & X_n^{*(B)} \sim N(0, S_n^2) \end{array} \end{array}$$

$$B \text{ varianzas muestrales: } S_n^{2*(1)}, \dots, S_n^{2*(B)}$$



- ① Estimador de la varianza:

$$\widehat{Var}_B(S_n^2) = \frac{1}{B-1} \sum_{l=1}^B (S_n^{2*(l)} - \bar{S}_B^{2*})^2$$

- ② Estimador del sesgo:  $\widehat{Bias}_B(S_n) = \frac{1}{B} \sum_{l=1}^B (S_n^{2*(l)} - S_n)$

- ③ Estimador de MSE:  $\widehat{MSE}(S_n^2) = \frac{1}{B} \sum_{l=1}^B (S_n^{2*(l)} - S_n^2)^2$

- ④ IC  $(1 - \alpha)$ :  $S_n^2 \pm z_{1-\alpha/2} \sqrt{\widehat{Var}_B(S_n^2)}$  (Normalidad asintótica)

- ⑤ IC  $(1 - \alpha)$ :  $[S_{n,\alpha/2}^{2*}, S_{n,1-\alpha/2}^{2*}]$  (Percentiles)

## ① Introducción

Antecedentes históricos

Generalidades

## ② Bootstrap No Paramétrico (Efron)

Método

Justificación Matemática para Bootstrap Clásico

## ③ Bootstrap Paramétrico

Método

## ④ Referencias



Chernick, M. (2008). *Bootstrap Methods. A guide for practitioners and Researchers*. Wiley.



Dikta, G., Scheer, M. (2021). *Bootstrap Methods with applications in R*. Springer.



Chernick, M., LaBudde, R. (2011). *An introduction to bootstrap methods with applications to R*. Wiley.



Politis, D., Romano, J., Wolf, M. (1999). *Subsampling*. Springer.



Urban, J.S. (1994). *Computer Intensive Statistical Methods*. Chapman & Hall.